

决赛赛题文档-面向参赛选手

初赛赛题总结

赛题说明

初赛赛题选定字节跳动开源多模态模型 Bagel 前向训练部分的 Attention 算子，围绕多模态场景下长序列带来的计算瓶颈以及复杂 Attention Mask 分布特征，要求选手在保证数值计算正确性的前提下，利用 CUDA 编程手动实现并优化高性能算子以缩减运行时间，重点对参赛选手的 GPU 架构理解、并行计算策略设计以及高性能计算（HPC）与 AI 深度融合的工程实践能力进行考察。

初赛赛题缺陷

考虑到赛题面向包括低年级的全校学生，为了降低低年级选手参与难度，赛题在 mask 类型构建上不具有现实性：

- mask 只选择了 Causal 模式（上三角矩阵），不匹配多模态 mask 特征

另外，初赛赛题还存在如下缺陷：

- 测例数量较多，部分测例规模重复
- 精度验证缺陷：固定精度阈值为 $1e-4$ ，未考虑使用tensor core加速后带来的实际精度损失

决赛赛题说明

决赛赛题在初赛的基础上，针对存在的问题进行完善，主要修改部分如下：

1. 补全多模态 mask 类别

补充除因果掩码外的其他类别掩码，具体内容如下：

- 文本内部注意力 (Text-to-Text)

因果掩码。与初赛掩码类型一致，矩阵的**主对角线及其左下方**区域为 0，**右上方**区域为 $-\infty$

- 跨模态注意力 (Text $\leftrightarrow$ VAE)

可见性掩码。矩阵分为两部分，右上角对应Text-to-VAE，反映文本是否能感知到图片；左下角对应VAE-to-Text，反映图片是否可以感知到文本

- VAE 自注意力 (VAE self-attention)

包含因果模式、局部窗口模式以及全关注模式。

因果模式同文本自注意

局部窗口模式的mask矩阵以主对角线为中心，形成一条宽度为 $2 \times \text{window} + 1$ 的“0带”，带状区域之外的所有元素均为 $-\infty$

全关注模式：mask 矩阵全0

```
162 # 1) Text-to-text: causal (default) or full
163 > if num_text_tokens > 0: ...
167
168 # 2) Text <-> VAE cross-attention
169 > if num_vae_tokens > 0 and num_text_tokens > 0: ...
177
178 # 3) VAE self-attention: full, causal, or local window
179 > if num_vae_tokens > 0: ...
194
195 # Note: attn is additive mask (0 = allow, -inf = block)
196 # Convert additive mask to per-sample boolean masks expected by PackedAttentionMoT.forward_train
197 # (List of tensors with shape (Li, Li), dtype=torch.bool, True == masked)
198 mask_bool = (attn == float('-inf')).to(torch.bool)
199 masks = []
200 idx = 0
201 for l in sample_lens:
202     if l <= 0:
203         masks.append(torch.empty((0, 0), dtype=torch.bool, device=device))
204     else:
205         masks.append(mask_bool[idx:idx+l, idx:idx+l].contiguous())
206     idx += l
207 # ===== build multimodal attention mask (end) =====
```

具体修改代码（参考 `run_multimodal.py` 160 - 194 行上下）

2. 精简测例

精简测例，选择十个具有现实意义的代表性样例，分别对应短指令对话、LLaVA 单图问答、多图对比分析等现实任务规模

```
1 FIXED_SHAPES = {
2     1001: (x,x,x,x),      # 极短指令/对话
3     1002: (x,x,x,x),      # 标准 LLaVA 单图问答
4     1003: (x,x,x,x),      # 1k 上下文边界测试
5     1004: (x,x,x,x),      # 多图对比分析。
6     1005: (x,x,x,x),      # 并发多图复杂任务
7     1006: (x,x,x,x),      # 高清切图 OCR
8     1007: (x,x,x,x),      # 短视频理解
9     1008: (x,x,x,x),      # 长文档/长视频
10    1009: (x,x,x,x),      # 投机采样验证/高吞吐
11    1010: (x,x,x,x),      #8k 上下文溢出鲁棒性测试
12 }
```

具体测例规模将于决赛最后一天给出

3. 完善脚本输出信息

在 custom ops 验证脚本 `OpenKernel/multimodal/custom_kernel/verify.py` 以及最终运行脚本 `OpenKernel/multimodal/run.py` 中添加针对半精度（FP16/BF16）和单精度（FP32）的分级验证逻辑。

```
66 # 半精度允许 5e-3 (0.005) 误差，全精度严格要求 1e-5
67 atol_val = 5e-3 if is_half else 1e-5
68 rtol_val = 5e-3 if is_half else 1e-5
```

具体修改代码

在最终运行脚本中添加精度验证部分，方便直观查看运算结果精度是否正确

```
=== Custom Kernel vs PyTorch算子顺序实现 验证（支持多模态掩码） ===
[verify] Using multimodal mask (prepare_multimodal_inputs)
验证（5次）汇总: worst_max_abs=3.841706e-09, avg_mean_abs=1.822698e-10, worst_max_rel=4.402608e-02, allclose_every_run=True, atol=1e-05, rtol=1e-05

===== NUMERIC VALIDATION PASSED =====
=== 数值验证通过: custom_attention 与 PyTorch 参考一致 ===
=== worst_max_abs=3.841706e-09, avg_mean_abs=1.822698e-10, worst_max_rel=4.402608e-02, atol=1e-05, rtol=1e-05 ===
```

注意事项

1. 决赛新增余下 mask 类型，选手若在初赛针对 mask 类型进行针对性优化，需要对新增类型进行分支判断处理

2. 决赛调整了精度验证部分的阈值，选手需要确保代码符合精度

3. 评分细则如下：

设 S 为 Bagel 题目的满分， P 为你的 Bagel 题目总分，其计算方法为：

$$P = \sum_{i=1}^N P_i$$

其中 P_i 为第 i 个测例的得分， $N = 10$ 。每个测例的得分分为正确性和性能两部分，计算方法为：

$$P_i = P_{i,c} * (1.5\% + 3.5\% * \frac{T_{i,min}}{T_i}) * S$$

其中 $P_{i,c}$ 为第 i 个测例的正确性，正确则为 1，不正确则为 0. $T_{i,min}$ 为第 i 个测例的全场最短用时， T_i 为你的第 i 个测例的用时。